

석 사 학 위 논 문

비용 예측 모형과 유전 알고리즘을 이용한
열처리로 작업 계획 최적화

허 형 록

부산대학교 대학원
전기전자컴퓨터공학과

2020년 2월

비
용
예
측
모
형
과
유
전
알
고
리
즘
을
이
용
하
는
작
업
계
획
최
적
화

허

형

록

2
0
2
0
·
2

비용 예측 모형과 유전 알고리즘을 이용한 열처리로 작업 계획 최적화

이 논문을 공학석사 학위논문으로 제출함

허 형 록

부산대학교 대학원

전기전자컴퓨터공학과

지도교수 류 광 렬

허 형 록 의 공학석사 학위논문을 인준함

2019년 12월 07일

위원장	채 흥 석	인
-----	-------	---

위 원	감 진 규	인
-----	-------	---

위 원	류 광 렬	인
-----	-------	---

차 례

I. 서론	1
II. 대상 문제	3
2.1. 열처리로 작업 계획 수립	3
2.2. 강괴 장입 시 제약	4
2.2.1. 권장 열처리 온도	4
2.2.2. 열처리로와 강괴의 폭	4
2.2.3. 예열이 필요한 강괴의 열처리로 할당	5
III. 관련 연구	6
IV. 제안 방안	8
4.1. 모델 학습을 통한 공정 예측	8
4.1.1. 가열 공정 데이터 학습	9
4.1.2. 프레스 공정 데이터 학습	9
4.1.3. 열처리 공정 데이터 학습	10
4.2. 학습된 모델을 이용한 시뮬레이터 구성	12
4.3. 유전 알고리즘을 이용한 해 탐색	13
4.3.1. 해의 표현	15
4.3.2. 해의 해석과 열처리로 할당	17
V. 실험 결과	19
5.1. 사용 데이터	19
5.2. 실험 환경	20
5.3. 평가 방안	21
5.4. 비교 대상	22
5.5. 실험 결과 및 분석	23
5.5.1. 모델 학습 결과	23

5.4.2. 유전 알고리즘으로 최적 계획 탐색	25
VI. 결론	29
VII. 참고 문헌	31

표 차 례

[표 1] 공정 설비 현황	19
[표 2] 공정 설비 성능표	19
[표 3] 유전 알고리즘 매개변수 설정	20
[표 4] 가열로 소요 시간 모델 MLP 성능 10회 측정 결과	23
[표 5] 가열로 소요 시간 모델 알고리즘 별 성능 측정 결과	23
[표 6] 열처리로 소요 시간 모델 MLP 성능 10회 측정 결과	24
[표 7] 열처리로 소요 시간 모델 알고리즘 별 성능 측정 결과	24
[표 8] 열처리로 소요 에너지 모델 MLP 성능 10회 측정 결과	25
[표 9] 열처리로 소요 에너지 모델 알고리즘 별 성능 측정 결과	25
[표 10] 제안 방안 시뮬레이션 결과	26
[표 11] 비교 방안 시뮬레이션 결과	26
[표 12] 제안 방안과 비교 방안 시뮬레이션 결과 비교	27

그 림 차 례

[그림 1] 단조 공정 흐름	1
[그림 2] 가열 공정 소요 시간 예측 모형	9
[그림 3] 단조 차수 예측 모형	10
[그림 4] 열처리 공정 소요 시간 예측 모형	11
[그림 5] 열처리 공정 소요 에너지 예측 모형	12
[그림 6] 공정 시뮬레이터	13
[그림 7] 유전 알고리즘	14
[그림 8] 유전 알고리즘 해 표현 방식 1	15
[그림 9] 유전 알고리즘 해 표현 방식 2	16

비용 예측 모형과 유전 알고리즘을 이용한 열처리로 작업 계획 최적화

허 형 록

부산대학교 대학원 전기전자컴퓨터공학과

요약

단조는 강괴를 고온으로 가열하고 원하는 형상으로 만드는 공정이다. 가열로에 강괴를 장입하여 가열하고, 고온의 강괴에 프레스 및 절단 공정을 적절히 반복하여 원하는 형상으로 만들 수 있다. 강괴를 원하는 형상으로 만든 뒤에는 강괴의 경도 및 강도를 조절하기 위해 열처리 공정을 진행한다. 열처리로는 여러 개의 강괴를 장입하여 가열하는데 이 과정에서 에너지와 비용이 많이 소모된다. 열처리 공정 시 소모되는 비용은 열처리 공정의 종류와 장입되는 강괴들의 특성 및 수량 등에 따라서 결정된다. 또한 공정 과정에서 동시에 처리하기 불가능한 강괴의 조합 또한 존재하며 현재 이는 현장 작업자의 판단 하에 결정된다. 따라서 열처리로에 장입할 강괴들의 조합을 최적화함으로써 비용을 최소화하고 현장 작업자의 부담을 줄일 수 있다.

따라서 본 논문에서는 비용 예측 모형과 유전 알고리즘을 이용하여 열처리로 작업 계획을 최적화하는 방안을 제안한다. 비용 예측 모형은 IoT 인프라를 기반으로 수집한 실제 공정 데이터를 이용한다. 다양한 열처리로 작업 계획은 학습한 모형 기반의 시뮬레이터를 통해 평가하여 유전 알고리즘을 기반으로 최적화한다. 최적의 열처리로 작업 계획을 수립함으로써 공정 비용을 최소화하고 에너지 효율을 극대화할 수 있다.

1 서론

단조는 가열, 프레스, 절단, 열처리 등의 공정을 통해 강괴를 원하는 형상으로 만드는 공정이다. 가열로에 강괴를 장입하여 고온에 가열하고, 원하는 형태로 만들기 위하여 압력을 가하는 프레스 공정과 강괴를 절단하는 공정을 적절하게 반복한다. 강괴의 형상이 원하는 대로 바뀌고 나면 경도 및 강도를 조절하기 위해 담금질과 같은 열처리 공정을 수행한다.

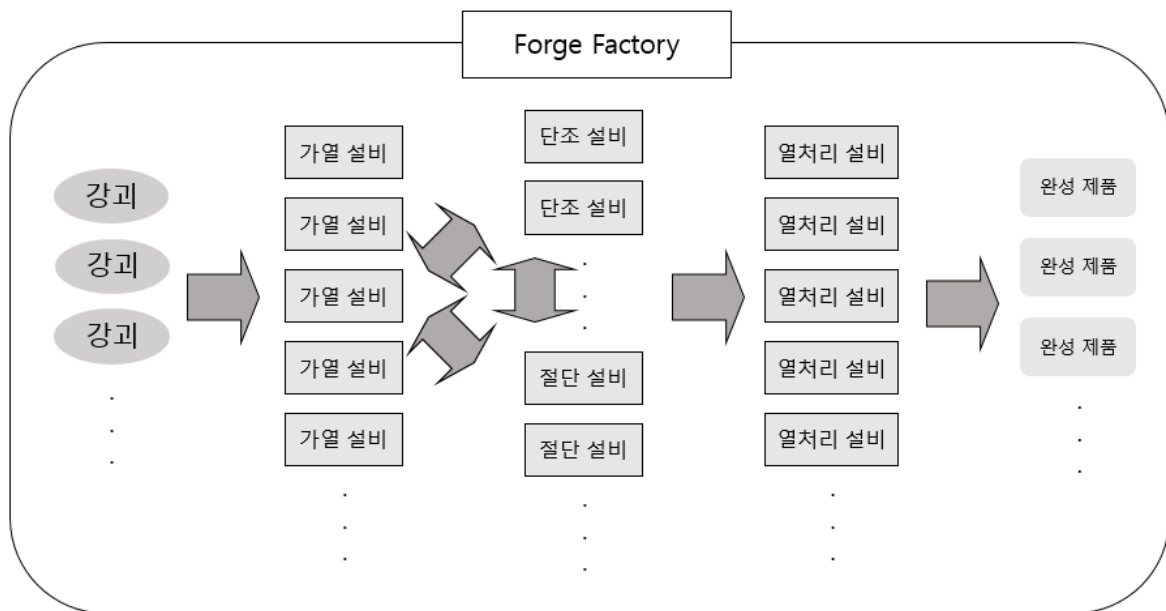


그림 1 단조 공정 흐름

열처리 공정은 열처리로의 용량이 허용하는 범위 내에서 한 번에 여러 강괴를 동시에 진행할 수 있는데, 이 때 열처리로에 한 번에 들어가는 강괴들의 조합에 따라 열처리 작업이 완료되기까지 걸리는 시간과 드는 비용이 크게 달라진다. 이는 강괴 별로 권장하는 열처리 온도나 시간이 달라서 발생하는 문제이며, 따라서 비슷한 성질의 강괴를 동시에 작업하는 것이 효율적이다.

실제 공장에서는 현장 관리자가 작업 별 공정 소요 시간과 에너지 소모량을 고려하여 각 열처리마다 수행할 작업들을 결정한다. 그러나 매일 처리해야 하는 열처리 공정 대상 작업이 매우 많고 공정 비용에 대한 정확한 추정이 어려우며 강과 장입에 있어서 여러 제약사항이 존재하기 때문에 이는 전적으로 현장 관리자의 직감에 의존하고 있다. 따라서 관리자가 가장 효율적인 계획을 수립하는 것은 현실적으로 어렵다.

본 연구에서는 열처리 공정 비용 예측 모형을 기반으로 다양한 열처리로 작업 계획에 대한 시뮬레이션을 통해 최적의 작업 계획을 수립하는 방안을 제안한다. 비용 예측 모형은 IoT 인프라를 기반으로 수집한 공정 데이터를 이용하여 학습하면 얻을 수 있다. 유전 알고리즘을 기반으로 학습 모형을 이용한 시뮬레이션을 수행하여 열처리로 작업 계획을 최적화한다.

본 논문의 구성은 다음과 같다. 2장에서는 열처리로에서의 계획 수립 문제와 장입 제약 문제를 정의하고, 3장에서는 관련 연구에 대해 소개한다. 4장에서는 본 논문에서 제안한 방안에 대해 서술하며, 5장에서는 실험 결과를 분석하여 제안 방안의 효용성을 확인한다. 마지막으로 6장에서는 결론을 맺으며 향후 연구방향을 제시한다.

2 대상 문제

이 장에서는 현장에서의 열처리로 계획 수립 방식에 대한 한계점을 설명하고 강괴 장입 시 고려해야 할 제약 조건에 대해 서술한다. 또한 현재 공장에서 IoT 인프라를 이용해 수집한 데이터를 살펴본다.

2.1 열처리로 작업계획 수립

열처리로는 7개가 존재하며 각 열처리로 별 미리 짜인 작업 계획을 바탕으로 그 날의 작업을 진행한다. 작업 계획은 전날 저녁에 열처리로 대상 물량을 보고 관리자가 수립한다. 일반적으로 마감 기한이 촉박한 작업일수록 먼저 작업하도록 하며, 열처리의 종류가 비슷한 작업들일수록 같은 로에 배치하여 효율성을 높이려 한다. 이 과정에서 같은 열처리로에 비슷한 작업만을 넣으려 하면 열처리로의 용량을 다 채우지 못하거나, 마감 기한이 많이 적게 남은 작업의 시작 시간이 뒤로 밀리게 되어 결과적으로 효율성이 떨어진다. 반대로 마감 기한이 얼마 남지 않은 작업만을 먼저 시작하려 하면 소요시간이 늘어나고 에너지 효율이 좋지 않게 된다. 마감 기한을 준수하는 범위 내에서 에너지 효율이 좋을수록 훌륭한 작업 계획이라 평가할 수 있다.

훌륭한 작업 계획을 찾기 위해 수많은 작업 계획 경우의 수를 모두 고려할 수 없기 때문에 본 연구에서는 유전 알고리즘을 이용하여 해의 탐색 범위를 좁혀가며 최적의 작업 계획을 탐색하고자 한다.

2.2 강괴 장입 시 제약

열처리로는 용량이 허용하는 내에서 한 번에 여러 강괴를 작업할 수 있다. 하지만 동시에 작업해서는 안 되는 경우가 있는데 첫 번째로 권장 열처리 온도가 서로 다른 강괴가 있는 경우이고, 두 번째로는 열처리로의 폭보다 강괴의 폭이 더 큰 경우이다. 또한 예열이 필요한 강괴는 해당 로가 가동되기 이전에 미리 로에 할당되어서 충분한 시간 동안 예열 과정을 거쳐야 한다.

2.2.1 권장 열처리 온도

권장 열처리 온도의 경우에는 강괴의 성질 뿐만 아니라 제품을 수주할 당시 구매자가 요청한 화학적 특성 목표치까지 고려되어야 한다. 화학적 특성은 열처리 온도에 따라 다르게 나타나며, 따라서 수주 당시의 목표 화학적 특성을 갖게 할 수 있는 열처리 온도를 학습을 통해 알아 내야 한다.

2.2.2 열처리로와 강괴의 폭

열처리로의 속성에는 길이, 폭, 높이와 장입 가능한 최대 중량이 있다. 길이와 높이는 충분히 길어서 고려하지 않아도 무방하지만 열처리로의 폭은 강괴의 폭보다 작으면 장입이 불가능하다. 총 7대의 열처리로는 각각 다른 속성을 가지고 있으며 이를 고려해서 장입 강괴를 선별해야 한다.

2.2.3 예열이 필요한 강괴의 열처리로 할당

강괴 중에는 열처리 작업 이전에 예열을 해야 하는 것들이 존재한다. 예를 들어 열처리 과정 B, 열처리 과정 C를 순차적으로 진행해야 하는 강괴 A가 있고 이 강괴의 열처리 과정 C가 진행되기 이전에 예열이 필요하다면, 열처리 과정 B가 완료되고 나서 열처리 과정 C가 진행되는 열처리로로 미리 장입한 뒤 예열을 진행해야 효율적으로 시간을 활용할 수 있다. 만일 미리 장입해야 할 열처리로가 작업 중이라면 비어있는 다른 열처리로에서 잠시 대기하다가 이동해야 한다.

3 관련 연구

공장의 계획 수립에 관한 연구는 이전에도 많이 존재한다. 그 중 단조 공장에서 열처리 공정의 작업 계획을 수리 모형을 이용하여 수립하는 방법을 제시한 연구가 존재한다.[3] 해당 연구는 일정 기간의 공장 데이터를 기반으로 수리적 연산을 통한 모델을 수립하여 효율적인 방식을 제안하였다. 본 연구는 이 연구와 다르게 예측 모형을 이용한 시뮬레이션으로 다양한 작업 계획을 평가해 가며 최적의 작업 계획을 수립하는 것을 목적으로 한다.

이전 연구 중 단조공장에서 가열 작업의 계획을 유전 알고리즘을 이용하여 최적화한 연구가 있다.[4] 해당 연구에서는 가열로가 작업을 선택하는 과정에서 유전 알고리즘을 이용하여 해를 최적화하였다. 본 연구는 열처리 이전의 가열 및 단조와 절단 작업이 모두 완료된 이후 열처리 대상 작업 목록을 기준으로 유전 알고리즘을 이용한 해 탐색을 통해 최적의 해를 찾는 것을 목표로 하고 있다. 또한 해당 연구는 작업의 계획을 최적화할 때 로의 장입 등에 대한 제약사항을 고려하지 않았으며, 본 연구는 제약사항을 만족함과 동시에 최적화된 작업 계획을 탐색하였다.

GA의 활용성에 관련된 연구 중 GA의 제약 사항 문제를 해결하기 위해 동적 패널티 함수(Dynamic Penalty Function)를 이용하는 방식과[6] constraint를 벗어나는 방식으로 진화를 유도하는 방식[7] 등을 다룬 기존 연구가 존재한다. 본 연구의 대상 문제와 유사하게 제약 사항을 만족하면서 목표 함수의 값을 최대치로 하는 해를 구하는 방식의 연구이지만, 성능이 좋은 기존 연구들이 real-value optimization이고, 본 연구는 combinatorial

optimization이라 적용이 불가능하다.

따라서 constraint를 위반하지 않으며 성능이 좋은 해를 탐색할 수 있는 새로운 방안에 대한 실험이 필요하다. 본 연구에서는 이 문제를 ‘항상 제약을 만족하는 해의 해석 방식’을 구현함으로써 해결하였다.

4 제안 방안

본 논문에서는 단조공장에서의 열처리 공정 계획 최적화를 위해 공장 데이터를 이용하여 공정 별 모델을 학습한 뒤, 이를 이용하여 작업 계획에 따른 결과를 확인할 수 있는 전체 공장 시뮬레이터를 구현한다. 작업 계획을 수립했을 때 해당 계획을 평가할 수 있다면 유전 알고리즘을 활용할 수 있게 되며, 시뮬레이터가 현실의 공장과 유사해서 작업 계획에 대한 평가 결과가 정확할수록 유전 알고리즘을 이용해 최적화된 작업 계획의 평가결과가 우수해진다.

시뮬레이터를 구성하기 위해 가열, 프레스, 열처리 각 공정들의 소요 시간을 학습하였으며, 해의 평가를 위해 열처리 공정의 소요 에너지 모델을 학습하였다. 또한 2.2.1에서 제안된 열처리 온도 관련 제약사항을 준수하기 위해 각 강괴의 속성과 목표 화학 성분에 따른 권장 열처리 온도 모델을 학습하였다.

4.1 모델 학습을 통한 공정 예측

효율적인 열처리 작업 계획을 수립하기 위해서는 어떤 작업 계획이 효율적인지 평가할 수 있어야 한다. 그리고 어떤 작업 계획이 효율적인지 평가하기 위해서는 작업 계획을 구성하는 요소들이 작업에 미치는 영향을 알아야 한다. 이를 위해 단조 공장의 흐름을 예측해야 하고, 따라서 각 공정 별로 소요 시간과 에너지 예측 값을 도출할 수 있어야 한다.

4.1.1 가열 공정 데이터 학습

가열 공정을 시뮬레이팅하기 위해서는 가열 시간 예측 모델이 필요하다. 가열 시간은 가열로에 장입된 강괴의 조합에 따라 천차만별이다. 각 강괴의 조합 별로 소요된 시간 데이터가 존재하며 이를 활용하여 학습하였다.

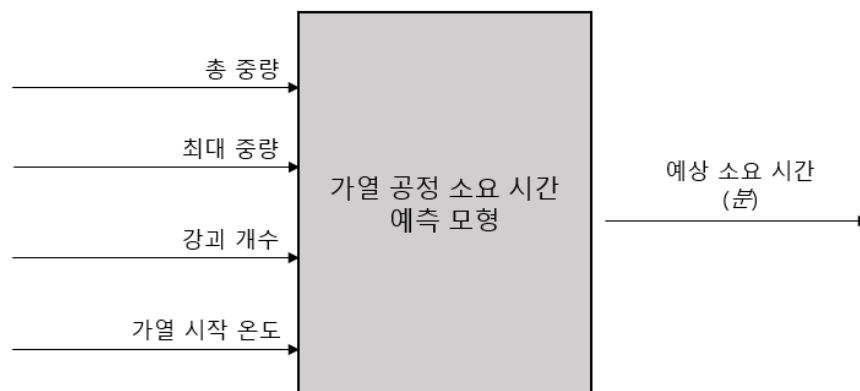


그림 2 가열 공정 소요 시간 예측 모형

4.1.2 프레스 공정 데이터 학습

특정 강괴가 어떤 공정을 거쳐야 하는지를 담은 정보를 ‘라우팅 정보’ 라고 한다. 라우팅 정보를 얻기 위해서는 강괴가 프레스 과정을 몇 번 거치는지 알아야 하는데 해당 데이터는 획득이 불가능해서 프레스기의 작업 내역 데이터를 가공하여 획득해야 한다. 동일한 Serial Number의 강괴에 대하여 프레스기의 작업 횟수를 카운트하고, 강괴의 속성을 Feature, 프레스 작업 횟수를 Label로 하여 모델을 학습한다. 이렇게 학습된 모델을 이용하여 특정 작업에 대하여 라우팅 정보를 유추해낼 수 있다.



그림 3 단조 차수 예측 모형

또한 특정 작업에 대해 프레스 공정을 소요 시간을 추정하기 위해서 학습 모델이 필요하다. 여러 대의 프레스기도 성능이 제각각이며 강괴의 크기와 재질, 할당된 프레스기의 성능에 따라 프레스 작업이 완료되기까지의 시간이 다르다. 이는 프레스기의 작업 내역 데이터에서 같은 작업에 대해 작업 시작 시간과 작업 완료 시간을 parsing하여 모델을 학습하는데 이용할 수 있다.

4.1.3 열처리 공정 데이터 학습

열처리 공정에서의 효율성은 평가기준에서 중요한 요소이기 때문에 소요 시간과 소요 에너지 둘 다 모델 학습이 필요하다. 열처리 공정 소요 시간과 소요 에너지는 둘 다 열처리 온도가 큰 영향을 미치는데, 열처리 온도의 경우에는 기존의 현장 관리자가 판단하던 내용

이라 데이터로 남아있지 않아서 추가적인 학습이 필요하다.

먼저 과거 열처리 내역을 바탕으로 강괴의 요구사항 문자열을 parsing하여 각 공정 별 요구사항으로 가공한 뒤, 이를 feature로 하고 해당 작업 내역 데이터의 작업 온도를 label로 하여 regression tree 모델로 학습한다. 모델이 학습된 이후에는 수주 데이터에서의 요구사항을 이용하여 권장 열처리 온도를 구할 수 있다. 또한 여러 강괴들의 권장 열처리 온도 범위 내에서 중간 값을 정의하여 이를 해당 강괴 조합의 열처리 온도로 활용할 수 있게 된다.

열처리로 소요 시간 예측 모델과 소요 에너지 예측 모델은 열처리 온도, 홀딩 시간, 장입 중량, 열처리 종류 별 유무를 이용하여 학습하여 획득할 수 있다.




그림 4 열처리 공정 소요 시간 예측 모형




그림 5 열처리 공정 소요 에너지 예측 모형

4.2 학습된 모델을 이용한 시뮬레이터 구성

공정 데이터를 이용하여 각 공정들을 가상으로 가동할 수 있다면 공정 사이의 연계 과정을 정의하여 전체 공정을 시뮬레이션할 수 있다. [그림 1]의 각 공정 사이에서 작업을 관리하고 인계하는 모듈을 설계하여 공정 계획을 가상으로 진행하고 각 계획 별로 처리한 열처리 작업의 양과 소모 에너지를 도출할 수 있다.

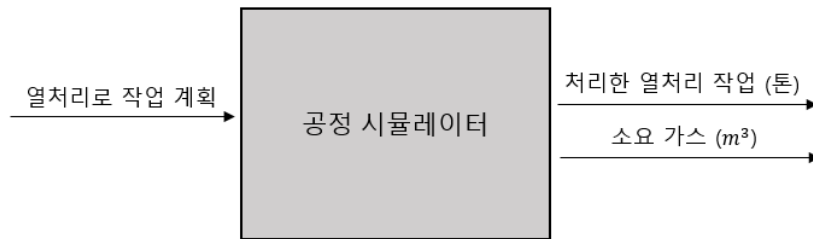


그림 6 공정 시뮬레이터

본 연구에서는 [그림 6]과 같은 시뮬레이터를 활용한 유전 알고리즘을 통해 해를 탐색하였다.

본 연구에서 공정은 하루 계획에 총 2회까지 계획될 수 있다. 1차 열처리 이후 예열과 2차 템퍼링 작업이 진행되는데, 이 사이에 예열이 진행되어야 하는 작업의 관리가 필요하다. 이는 예열 관리 모듈을 시뮬레이터 내에 구현하여 해결하였으며, 2차 템퍼링 작업을 진행하기 전 예열 중이던 작업이 모두 다른 열처리로 옮겨질 수 있는지 확인하고 작업을 진행하게 된다.

4.3 유전 알고리즘을 이용한 해 탐색

유전 알고리즘은 자연의 진화과정을 모방하여 만든 알고리즘으로서, 다양한 해를 평가하고 우수한 해들을 교배하여 새로운 해를 생성하는 과정을 반복해 가며 점차적으로 우수한 평을 받는 해를 찾아가는 최적화 알고리즘이다. 다양한 공정 작업 계획을 평가하면서도 유전 알고리즘을 이용하여 탐색 범위를 좁힘으로써 효율적으로 최적의 작업 계획을 수립할 수

있다.

수립한 계획을 평가하기 위하여 현실의 공장에서 성능을 측정하여야 하지만, 현실적으로 불가능한 방법이라 동일한 예측 모형에 기댓값 10%의 오차를 적용하여 성능 평가 시뮬레이터로 이용하였다. 가상 공장 시뮬레이터에서 7일씩 가동한 뒤 가장 성능이 좋았던 작업 계획을 실제 공장 시뮬레이터에 적용하여 하루 동안 가동하고 평가한다. 하루가 지난 뒤에는 실제 공장 시뮬레이터의 상황을 반영하여 7일간 새로운 작업 계획을 수립하고, 이를 실제 공장 시뮬레이터가 7일동안 가동되도록 반복한다.

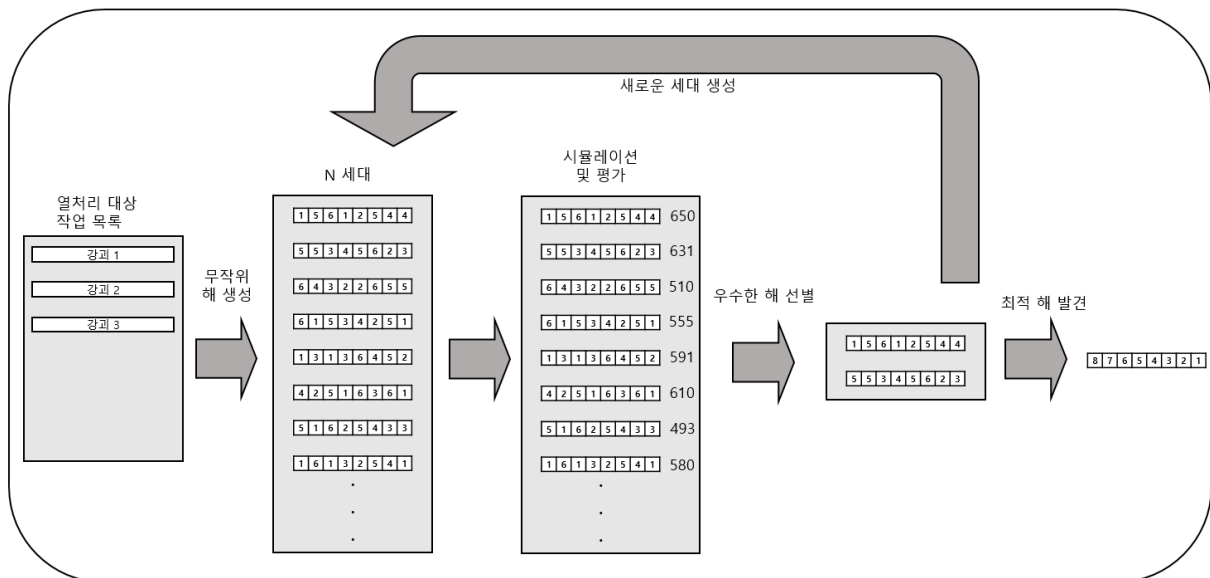


그림 7 유전 알고리즘

4.3.1 해의 표현

앞서 살펴본 연구들에서는 해의 표현이 단순하고, 제약 사항을 위반할 때에는 패널티를 부여함으로써 제약 만족을 유지하였다. 따라서 본 연구에서도 유사한 해 표현 방식을 채택하여서 실험을 진행하였다.

우선 본 연구에서는 열처리로의 하루 동작이 최대 3개의 구간(열처리, 예열, 열처리)으로 구분될 수 있기 때문에 해를 세 개의 구간으로 나누어 해석한다. [그림 8] 이 해당 방식으로 표현한 해이다.

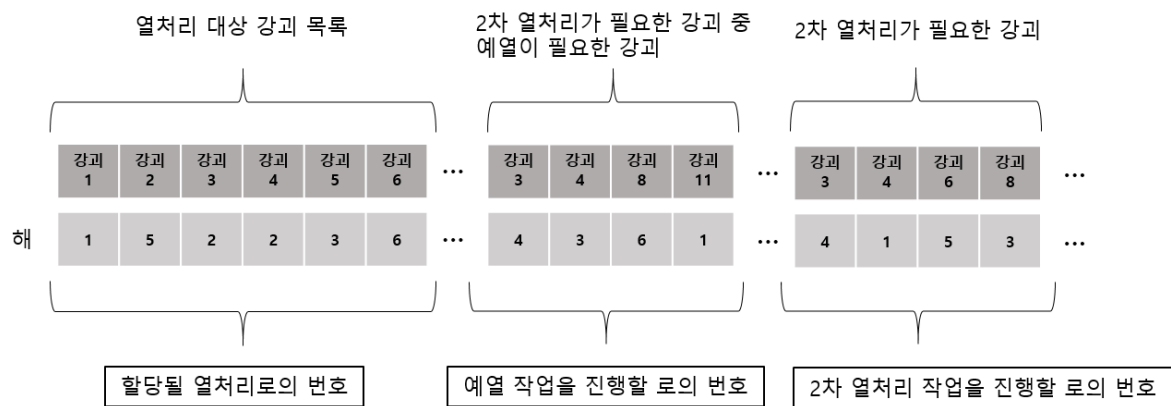


그림 8 유전 알고리즘 해 표현 방식 1

해의 교차는 세 부분이 각각 따로 일어나며, 따라서 한 번의 교차 작업 중 총 3번의 교차 연산이 이루어진다. 각 부분의 교차가 완료되고 나면 조합하여 새로운 해가 생성된다. 이 방식으로 첫 실험을 진행하였으나 제약사항을 만족하는 해를 찾을 수 없었는데, 이는 방대한 해 표현 범위에 비해 제약 만족 범위가 매우 좁으며, 해의 제약 위반 정도가 linear하게 증가하지 않기 때문인 것이라 판단된다.

따라서 해의 표현에서부터 제약을 위반하지 않는 방식을 이용하여 탐색을 진행하기 위하여 표현 방식을 [그림 9]와 같이 변경하였다.

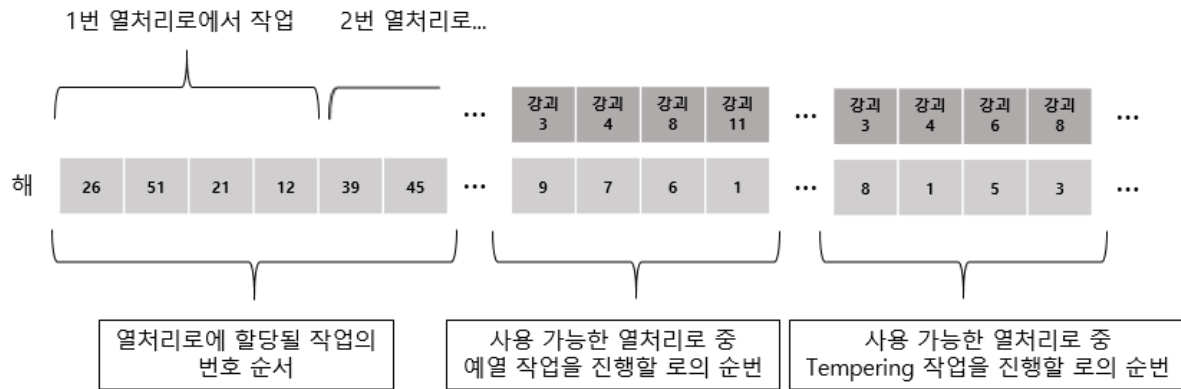


그림 9 유전 알고리즘 해 표현 방식 2

해는 총 세 가지 요소를 포함하고 있다. 첫 번째는 열처리 작업 대상 강괴들의 번호를 중복 없이 나열한 부분이다. 앞에서부터 각 열처리로의 용량이 허락하는 내에서 최대한의 강괴를 장입한다. 또한 이미 장입된 강괴를 기준으로 같이 작업할 수 있는 강괴들만 골라서 장입한다. 예를 들어, 이미 장입된 여러 강괴와 다음 번 강괴가 같이 작업이 불가능하다면 장입하지 않는 식이다. 용량을 초과하는 양의 장입이 일어나지 않기 때문에 용량의 제약으로부터 자유로우며, 또한 열처리 온도 제약을 위반하는 일이 일어나지 않기 때문에 해당 제약으로부터도 자유롭다. 두 번째 부분은 강괴의 예열 작업을 진행할 때, 예열 작업이 가능한 열처리로 중 순번을 나타낸다. 세 번째는 강괴의 2차 Tempering 작업을 진행할 때, 작업을 할 수 있는 열처리로 중 순번을 나타낸다.

4.3.2 해의 해석과 열처리로 할당

4.3.1장에서 서술한 바와 같이 첫 번째 부분을 제외한 나머지 유전자는 동적으로 해석 당시 할당될 열처리로의 순번을 의미한다. 여기서 말하는 순번이란 장입 제약 등으로 할당할 수 없는 열처리로를 제외하고 할당 가능한 열처리로 목록 들 중 n 번째 열처리로를 의미한다. 해의 생성 당시에는 해당 정보를 알 수 없으므로 유전자 번호가 할당 가능한 열처리로의 개수보다 커지는 경우가 있는데, 이 경우에는 할당 가능한 열처리로의 개수로 modular 연산을 한 뒤 해석한다. 예를 들어 할당 가능한 열처리로의 개수가 4개인 강괴의 해 할당 유전자가 6이라면 이 강괴의 유전자는 2와 동일한 것으로 보고 세 번째 할당 가능한 열처리로에서 작업을 진행하도록 한다. 위와 같이 해석함으로써 강괴의 모든 열처리로 할당 경우를 표현할 수 있게 되고 강괴의 작업을 다음 날로 미루는 경우까지 표현할 수 있게 된다. 또한 정적으로 열처리로 번호를 할당함으로써 생기는 제약 위반 문제로부터도 자유롭게 된다.

한 번의 열처리 과정만 거치고 모든 열처리 공정이 끝날 수도 있고, Tempering 과정을 추가로 거쳐야 모든 열처리 공정이 끝날 수도 있다. 또한 그 중에는 예열을 해야 하는 작업 또한 존재하는데 이를 표현하기 위하여 해를 크게 세 부분으로 나누어 해석한다.

첫째로 열처리로 할당 부분이다. 각 열처리로가 어떤 강괴를 할당할지 표현되는 부분이며, $0 \sim \text{'작업의 개수'} - 1$ 까지를 범위로 갖는다. 각 열처리로는 해의 앞 부분의 할당되지 않은 작업부터 순서대로 제약사항을 어기지 않고 용량이 허락하는 내에서 최대한의 강괴를 장입한다. 모든 로가 장입한 이후 남은 강괴는 해당일에 처리하지 않는 작업으로 생각한다.

둘째로 예열 작업이 진행될 로를 결정하는 부분이다. 열처리 공정을 두 번 거쳐야 하는 강괴들 중 Tempering 작업이 필요한 경우 중 첫 번째 열처리 공정 이후 일정 온도 이상으로 강괴를 유지시켜야 하는 경우가 존재하는데, 이 때 임시로 장입될 열처리로의 순번을 의미한다.

셋째로 Tempering 작업이 진행될 로를 결정하는 부분이다. 열처리 공정을 두 번 거쳐야 하는 강괴들 중 Tempering 작업이 필요한 경우에는 당일에 작업을 두 번 하는 경우가 존재하는데, 이 때 장입될 열처리로의 순번을 의미한다.

5 실험 결과

본 장에서는 앞에서 제안한 단조 공장의 열처리 공정 작업계획 최적화 시스템의 성능을 측정하기 위한 시뮬레이션의 결과 및 비교 방안과의 분석에 대해 서술한다.

5.1 사용 데이터

실험 환경을 실제 환경과 유사하게 구성하기 위하여 실제 운영중인 공장을 선정하여 이를 배경으로 실험을 수행하였다. 대상 공장은 ㈜태웅 이며 해당 공장의 실제 과거 공정 데이터를 수집하고 이를 바탕으로 실험 환경을 설계하였다. ㈜태웅의 설비 현황은 [표 1]과 같다.

가열로	13대
프레스기	3대
절단기	2대
열처리로	7대

표 1 공정 설비 현황

가열로 13대, 프레스기 3대, 절단기 2대, 열처리로 7대의 설비가 존재하며 해당 연구에서의 최적화 목적이 되는 열처리로 설비의 성능은 [표 2]와 같다.

	용량 (톤)	길이 (mm)	높이 (mm)	폭 (mm)
1호기	120	10,700	2,000	3,490

2호기	150	13,450	2,000	3,490
3호기	200	11,500	3,000	5,200
4호기	200	11,500	3,000	5,600
5호기	200	11,500	3,000	5,600
6호기	120	10,700	2,000	3,490
7호기	150	16,400	2,000	3,490

표 2 공정 설비 성능표

모든 설비는 용량과 크기를 초과하는 양의 강괴를 장입할 수 없으며, 가열, 프레스, 절단, 열처리 이외의 공정은 고려하지 않는다.

실험에 사용된 데이터는 2014년부터 2019년 10월까지 ㈜태웅의 가열로, 프레스기, 열처리로의 작업 내역과 수주 정보이며 이를 가공하여 사용하였다.

5.2 실험 환경

유전 알고리즘으로 작업 계획을 탐색하기 위한 매개변수 설정은 [표 3]과 같다.

알고리즘	RTS
개체군	1000
교배 풀 크기	2
총 평가 횟수	100000회

표 3 유전 알고리즘 매개변수 설정

유전 알고리즘으로는 RTS 알고리즘을 사용하였다. 개체군의 크기는 1000, 교배 풀과 비교 대상 풀의 크기는 각각 2와 100으로 설정하였다. 교차 확률은 0.2로 설정하였다. 돌연변이 확률은 $(1/\text{유전자의 길이})$ 로 설정하였다. 최종적으로 100000회까지 평가를 하고 탐색을

종료하며 가장 우수한 해를 선별한다.

5.3 평가 방안

본 논문에서 해결 대상 문제는 열처리로의 작업 계획 최적화이며 따라서 이를 위한 정의가 필요하다. 열처리로 작업 계획의 성능은 다음과 같이 평가하기로 한다.

‘처리한 총 중량(톤) $\times w_1$ + 소모한 가스(m^3) 당 처리한 중량(톤) $\times w_2$ - 마감기한을 어긴 작업 수 $\times w_3$ ’

이는 연구에서 목표로 하는 바가 제한된 시간 내에 더욱 많은 열처리 작업을 처리하며 에너지 효율을 좋은 수준으로 유지하는 것이기 때문이며, 따라서 평가값이 높을수록 좋은 계획이라 정의할 수 있다.

위의 평가식에서 가중치는 $w_1=1$, $w_2=5000000$, $w_3=100$ 으로 설정하였다. 이는 가스 사용량의 단위 수치가 처리 중량의 단위보다 너무 커서 적절한 반영을 위해 보정이 필요하기 때문이다. 가중치 w_1 을 높인다면 본 알고리즘은 에너지 효율보다 제한 시간 내에 처리한 중량이 많은 계획을 결과로 도출할 것이고, 가중치 w_2 를 높인다면 본 알고리즘은 처리한 중량보다는 에너지 효율이 좋은 계획을 결과로 도출할 것이다.

5.4 비교 대상

본 논문에서 제안한 방안과 비교하여 분석할 방안으로는 열처리 할당을 위한 Heuristic Algorithm을 선정하였다. 해당 Heuristic Algorithm은 실제 현장에서의 방식을 차용하여 설계하였다.

Heuristic Algorithm은 열처리로가 가동 가능한 상황이 될 때마다 마감 기한이 가장 적게 남은 작업을 선택하고, 마감 기한 순으로 해당 작업과 같이 열처리 작업이 가능한 강괴를 골라가며 열처리로의 용량이 채워질 때까지 장입하는 방식이다.

실제 공장에서는 열처리 작업 사이에 예열을 해야 하는 작업이 존재하지만 이를 합리적으로 구현해내기 어려운 면이 있어서, Heuristic Algorithm은 해당 문제를 무시하고 계획을 하며 패널티를 전혀 받지 않는다고 가정한다. 제안 방안인 Genetic Algorithm을 이용한 방식은 예열 로를 선정하고 운용하는 방식을 유지한다. 따라서 계획의 효율성이 비슷하다면 Heuristic Algorithm이 더욱 좋은 결과를 내게 될 것이다.

본 논문의 제안 방안과 비교 및 평가를 하기 위해서 동일한 수주 데이터를 기반으로 계획을 수립하여 시뮬레이션한다.

5.5 실험 결과 및 분석

5.5.1 모델 학습 결과

아래는 가열로 소요 시간 모델의 학습 결과이다. 모델의 input으로는 ‘총 중량, 최대 중량, 강괴 개수, 가열 시작 온도’가 있다. K-NN, MLP, M5P 세 가지 알고리즘에 대하여 성능을 측정하였으며 MLP는 무작위성이 존재하기에 10회 평가 후 평균값을 이용하여 비교하였다.

	Mean Absolute Error
1 회	14.46095753
2 회	13.29546928
3 회	13.15285778
4 회	13.28660488
5 회	12.50566292
6 회	13.57640457
7 회	14.4794426
8 회	14.55060863
9 회	14.34901905
10 회	13.17039871
평균	13.6827426

표 4 가열로 소요 시간 모델 MLP 성능 10회 측정 결과

	Mean Absolute Error
K-NN	18.98
MLP	13.68
M5P	12.7

표 5 가열로 소요 시간 모델 알고리즘 별 성능 측정 결과

총 세 가지 방식으로 학습하고 성능을 비교해 본 결과 M5P가 MAE 측면에서 가장 우수하여 해당 모델을 사용하였다.

아래는 열처리로 소요 시간 모델의 학습 결과이다. 모델의 input으로는 ‘열처리 온도, 홀딩 시간, 총 강괴 중량, 각 열처리 공정의 유무’가 있다.

	Mean Absolute Error
1 회	17.64120865
2 회	14.90370941
3 회	8.33680439
4 회	15.63723469
5 회	14.81925201
6 회	17.0203495
7 회	14.89547157
8 회	19.48643494
9 회	12.75095367
10 회	12.92135143
평균	14.84127703

표 6 열처리로 소요 시간 모델 MLP 성능 10회 측정 결과

	Mean Absolute Error
K-NN	11.74 (k=5)
MLP	14.84
M5P	9.13

표 7 열처리로 소요 시간 모델 알고리즘 별 성능 측정 결과

마찬가지로 세 가지 방식으로 학습하고 성능을 비교해 본 결과 M5P가 MAE 측면에서 가장 우수하여 해당 모델을 사용하였다.

아래는 열처리로 소요 에너지 모델의 학습 결과이다. 모델의 input으로는 열처리로 소요 시간 모델과 동일한 ‘열처리 온도, 홀딩 시간, 총 강괴 중량, 각 열처리 공정의 유무’에 추가로 ‘열처리 소요 시간’이 있다.

	Mean Absolute Error
1 회	15.43646841
2 회	14.57027988
3 회	14.22337488
4 회	14.67612351
5 회	12.88850914
6 회	16.09785514
7 회	12.97122345
8 회	12.99696131
9 회	13.37649247
10 회	15.15939991
평균	14.23966881

표 8 열처리로 소요 에너지 모델 MLP 성능 10회 측정 결과

	Mean Absolute Error
K-NN	15.97 (k=10)
MLP	14.23
M5P	15.02

표 9 열처리로 소요 에너지 모델 알고리즘 별 성능 측정 결과

이 역시 앞선 모델들과 마찬가지로 세 가지 알고리즘을 이용하여 성능을 비교하였고 MLP가 MAE 측면에서 가장 우수하여 해당 모델을 사용하였다.

5.5.2 유전 알고리즘으로 최적 계획 탐색

태웅 공장의 19년도 수주 데이터를 이용하였고, 하루씩 7번을 반복하여 7일의 계획을

수립하고 평가하였다. 매일 열처리로의 계획을 수립하는 시점에서의 열처리로 대상 작업 목록을 대상으로 계획을 수립하며, 하루 동안 열처리로가 가동되고 나서 다시 대상 작업 목록을 갱신하여 다음 날의 작업 계획을 수립한다.

본 연구에서는 8개의 수주 데이터에 대하여 시뮬레이션 하였으며, 제안 방안의 결과는 [표 10]와 같다.

실험 번호	에너지 사용량	총 생산량	에너지 당 생산량
1	9399269	7533	801
2	7712097	6160	799
3	7656934	6363	831
4	7713284	6395	829
5	7033035	5820	828
6	7394975	5629	761
7	7000464	6104	872
8	4737637	3447	728
평균	7330961	5931	806

표 10 제안 방안 시뮬레이션 결과

다음 [표 11]은 비교 방안인 Heuristic Algorithm의 결과이다.

실험 번호	에너지 사용량	총 생산량	에너지 당 생산량
1	7070886	5750	813
2	7290194	5990	822
3	8501032	6310	742
4	7692011	5832	758
5	8559771	5798	677

6	7729228	4404	570
7	7467418	5372	719
8	4582318	3155	689
평균	7361607	5326	724

표 11 비교 방안 시뮬레이션 결과

두 방안의 결과를 비교해 보면 다음 [표 12]와 같다.

	제안 방안			비교 방안		
실험 번호	에너지 사용량	총 생산량	에너지 당 생산량	에너지 사용량	총 생산량	에너지 당 생산량
1	9399269	7533	801	7070886	5750	813
2	7712097	6160	799	7290194	5990	822
3	7656934	6363	831	8501032	6310	742
4	7713284	6395	829	7692011	5832	758
5	7033035	5820	828	8559771	5798	677
6	7394975	5629	761	7729228	4404	570
7	7000464	6104	872	7467418	5372	719
8	4737637	3447	728	4582318	3155	689
평균	7330961	5931	806	7361607	5326	724

표 12 제안 방안과 비교 방안 시뮬레이션 결과 비교

비교표에서 확인할 수 있는 것처럼 제안 방안의 총 생산량이 비교 방안의 총 생산량보다 유의미하게 높음을 알 수 있다. 에너지 사용량의 경우에는 제안 방안과 비교 방안에서 서로 비슷했지만 같은 에너지로 얼마나 많은 생산을 하였는지를 나타내는 지표인 ‘에너지 당 생산량’을 보면 제안 방안이 비교 방안에 비해 약 11% 높음을 확인할 수 있다. 이는 에너지 효율이 좋고 작업 시간이 빠른 강괴의 조합을 찾아내는 쪽으로 GA가 진화하였기 때문으로 판단된다. 효율적인 강괴의 조합을 탐색함으로써 비슷한 에너지 사용으로 많은 작업을 진행

할 수 있게 된다.

6 결론

본 논문에서는 단조 공장에서의 작업 계획을 각 공정 별 예측 모형과 시뮬레이터 기반의 유전 알고리즘을 이용하여 최적화하는 방법을 제안하였다. 실제 공장의 데이터를 수집하여 학습한 예측 모형을 이용하여 시뮬레이터를 구성하였고, 이를 이용하여 유전 알고리즘의 해를 평가하였다.

해당 연구에서는 유전 알고리즘 해의 조합에 따라 제약이 생기므로 이를 해결하기 위한 방안이 필요하였다. 기존에 존재하던 GA의 제약 만족 연구는 대부분 real-value optimization이지만, 본 연구에서는 GA가 combinatorial optimization이기 때문에 이전의 연구에서 쓰였던 방식들과 다르게 이를 해결하기 위한 방안이 필요하였고, 항상 제약을 만족하는 해의 해석 방식을 고안하여 이용하였다.

제안 방안의 효과를 검증하기 위해서 현장에서 실제로 공정 계획을 수립하는 방안과 유사한 방식을 차용한 Heuristic Algorithm과 성능을 비교하였으며, 최종적으로 처리한 톤 수와 소요 에너지 당 처리한 톤 수를 적절히 가중하여 분석한 결과, 비교 방안이 예열 로 선정 부분에서 유리하게 적용되었음에도 불구하고 제안 방안의 효율성이 더욱 뛰어남을 확인할 수 있다.

또한 연구에서 GA의 목표 함수가 총 생산량을 늘리는 데에 높은 가중치를 부여하여 해당 결과가 도출되었음을 미루어 볼 때, 목표 함수에서 에너지 효율성에 높은 가중치를 부여한다면 비슷한 작업량 대비 에너지 사용이 유의미하게 감소할 수 있을 것으로 보인다. 추후

알고리즘의 가중치를 현장 상황에 맞게 최적화하는 방향으로의 연구도 진행이 가능하다.

다만 본 논문에서는 특정 단조 공장의 데이터와 작업방식을 이용하여 연구를 진행하였으므로 설비나 작업 방식이 다른 공장에 대해서도 해당 방안을 적용하기에는 한계가 있을 것으로 간주된다. 하지만 많지 않은 데이터를 이용하였고 열처리로에 대한 최적화만으로 유의미한 성과를 보이므로, 충분히 많은 데이터가 확보되고 나서 다른 공정들도 최적화한다면 더욱 훌륭한 결과를 낼 수 있을 것으로 보인다.

7 참고 문헌

- [1] Zouhal, Lalla Meriem, and Thierry Denoeux. "An evidence-theoretic k-NN rule with parameter optimization." *IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews)* 28.2 (1998): 263-271.
- [2] Gardner, Matt W., and S. R. Dorling. "Artificial neural networks (the multilayer perceptron)—a review of applications in the atmospheric sciences." *Atmospheric environment* 32.14-15 (1998): 2627-2636.
- [3] 최민철, "열처리 공정의 생산스케줄 수립과 적용에 관한 연구." *경영과학* 29.2 (2012): 143-155.
- [4] 이정미, 김세영, 류광렬. "열간 자유 단조공정의 에너지 효율화를 위한 모형 기반 작업 계획 최적화". 2018년 추계학술발표대회 논문집 25.2
- [5] Dadios, Elmer P., and Jamshaid Ashraf. "Genetic algorithm with adaptive and dynamic penalty functions for the selection of cleaner production measures: a constrained optimization problem." *Clean Technologies and Environmental Policy* 8.2 (2006): 85-95.
- [6] Joines, Jeffrey A., and Christopher R. Houck. "On the use of non-stationary penalty functions to solve nonlinear constrained optimization problems with GA's." *Proceedings of the First IEEE Conference on Evolutionary Computation. IEEE World Congress on Computational Intelligence*. IEEE, 1994.
- [7] Mezura-Montes, Efrén, and Carlos A. Coello Coello. "A simple multimembered evolution strategy to solve constrained optimization problems." *IEEE Transactions on Evolutionary computation* 9.1 (2005): 1-17.
- [8] Harik, Georges R. "Finding Multimodal Solutions Using Restricted Tournament Selection." *ICGA*. 1995.

Model, GA-based Scheduling Optimization of Heat Treatment Furnaces in Hot Press Forging Factory

Hyeongrok Heo

Department of Electrical and Computer Engineering
The Graduate School
Pusan National University

Abstract

Forging is the process of heating the ingot to a high temperature and forming it into a desired shape. The ingot may be charged into a heating furnace and heated, and the pressing and cutting processes may be appropriately repeated for the high temperature ingot to obtain a desired shape. After the ingot is formed into the desired shape, heat treatment is performed to control the hardness and strength of the ingot. The heat-treating furnace charges and heats several ingots, which consumes energy and cost. The cost consumed during the heat treatment process depends on the type of heat treatment process and the characteristics and quantity of the ingots to be charged. There is also a combination of ingots that cannot be processed simultaneously in the process and is currently determined at the operator's discretion. Therefore, by optimizing the combination of ingots to be charged into the heat treatment furnace, the cost can be minimized and the burden on workers can be reduced.

Therefore, in this paper, we propose a method of optimizing the heat treatment furnace work plan using cost prediction model and genetic algorithm. Cost prediction models use actual process data collected based on IoT infrastructure.